PORTFOLIO

정해원
Hae won Jeong

중앙대학교 AI학과 (2022.03~2026.02)
Chung-Ang University, Dept. of Artificial Intelligence

haewon20430@naver.com | haewon0430@cau.ac.kr | https://github.com/haewon22

Research Project 1

2025.09 ~ 2025.12

Training-free Spatial Reasoning 개선 및 성능 상한 분석

- VLM이 '왼쪽/오른쪽'과 같은 단순한 공간 관계도 제대로 추론하지 못하는 문제 분석
  - 프롬프트 및 Attention 조정 기반 접근의 근본적 한계를 실증적으로 규명

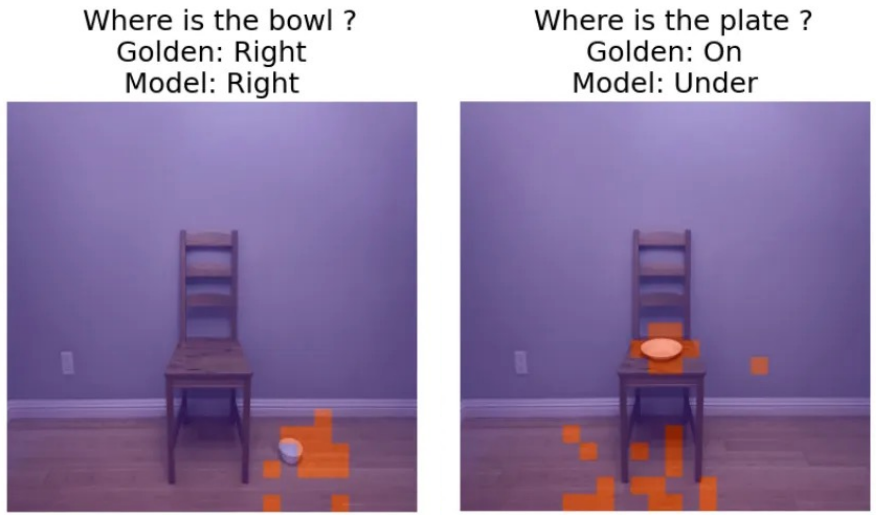

Baseline 논문

Why is Spatial Reasoning Hard for VLMs?

An Attention Mechanism Perspective on Focus Area

🔗 Link: https://arxiv.org/pdf/2503.01773

[요약]

- **VLM의 spatial reasoning**을 **attention 관점에서 분석**한 연구
- 오답 시 attention이 무관한 객체로 향한다는 점을 발견
- 이를 바탕으로 confidence를 기반으로 **attention을 sharpening/smoothing하는 training-free decoding 방법을 제안**

본 프로젝트는 AdaptVis 프레임워크를 기반으로

1) 불확실성 지표가 문제인가

2) 전략 자체가 상한을 가지는가

두 가설을 순서대로 검증하는 것을 목표로 했다.

또한, 프롬프트로 성능을 끌어낼 수 있는지 추가 실험을 진행하였다.

Research Project 1

Uncertainty 지표 대체

RQ. top-1 confidence는 1등이 얼마나 확실한지를 보지만, 2등 후보와 차이가 없는 상황을 반영하지 못한다.
Entropy/JSD처럼 분포 전체를 보는 지표가 이 경우를 더 정확히 식별할 수 있을까?

문제 상황 예시
A: P=[0.50,0.40,0.05,0.05] → margin = 0.10 → 답 후보 간 확신이 부족한 상태
B: P=[0.50,0.17,0.17,0.16] → margin = 0.33 → 상대적으로 확신하는 상태
그러나 두 경우 모두 Confidence = 0.50로 동일하다.

Baseline: AdaptVis

1) 1차 생성에서 top-1 confidence로 uncertainty 계산

2) threshold로 attention distribution weight1 vs weight2 선택

- uncertain → smoothing (weight↓)
- confident → sharpening (weight↑)

Proposed: Distribution-aware Uncertainty

관계 옵션 토큰(Left/Right/On/Under)만 추출해 분포 P를 구성 후:

1) Confidence: $\max(P)$

2) Entropy: $H(P)$

3) JSD: $JSD(P \parallel U)$, (U = uniform)

Results
Confidence, Entropy, JSD에서 성능 차이가 없었다.

Metric	Controlled A	Controlled B	COCO	VG
Confidence (기존)	84.9	83.8	56.8	45.4
JSD	84.9	83.8	56.8	45.4
Entropy	85.0	83.9	56.9	45.5

Metric간 상관관계 분석

	Confidence	JSD	Entropy
Confidence	1.000	0.947	-0.962
JSD	0.947	1.000	-0.981
Entropy	-0.962	-0.981	1.000

Controlled A 데이터셋에서 각 지표의 Pearson 상관계수

분포 기반 지표(Entropy/JSD)를 도입했지만, **실제 관계 토큰 분포가 대부분 이미 sharp하게 형성되어있어** 분포 전체를 보는 지표가 기대한 만큼 새로운 구분을 만들지 못했고, 결과적으로 weight 선택도 크게 달라지지 않아 성능 차이가 없었다.

Research Project 1

성능 상한의 발견

RQ. uncertainty 기반 binary weight selection 전략이 낼 수 있는 **최대 성능은 어디까지일까?**

Method

1) 각 샘플에 대해 0.5와 1.5 weight을 각각 적용해 얻은 예측이 정답인지 여부를 미리 저장
2) Threshold를 전 구간 sweep하여 best weight accuracy 계산
3) Oracle(upper bound): 샘플마다 low/high 중 맞는 쪽이 하나라도 있으면 정답으로 간주
*Oracle = 이 pair(low/high)에서 이론적으로 가능한 최고 성능

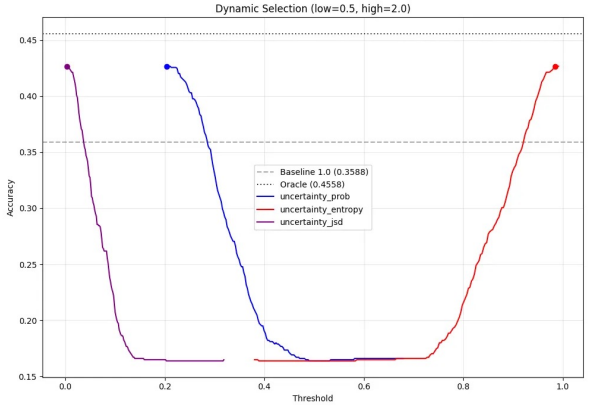

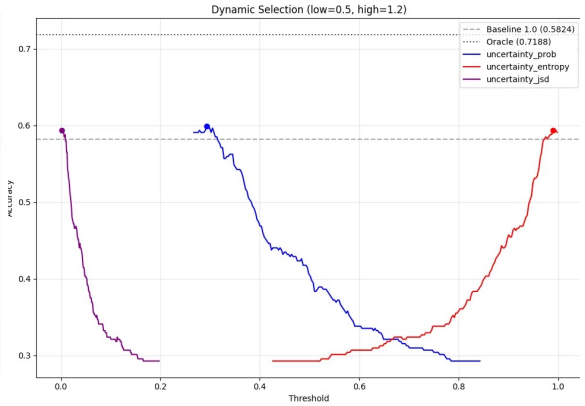

Controlled Images (Controlled_images_A/B)

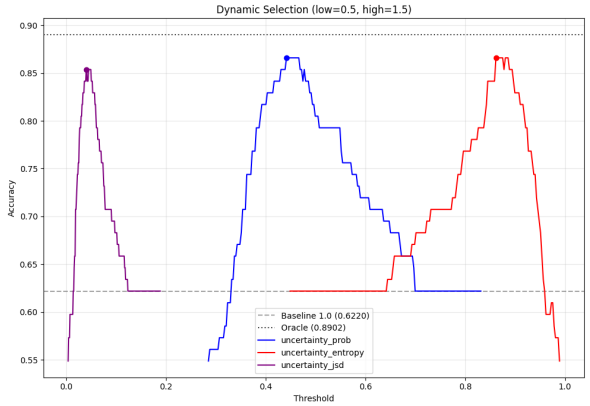

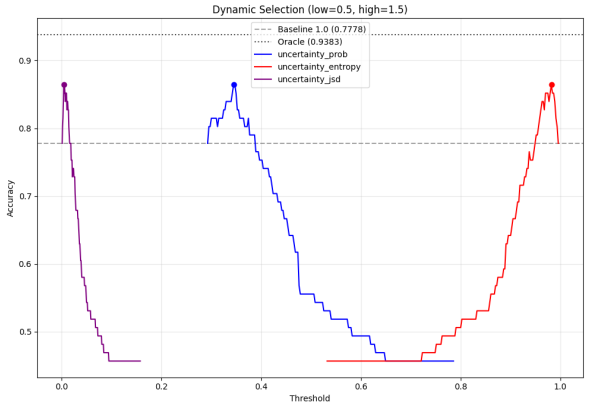

Real Images (COCO_QA, VG_QA)

정답을 아는 오라클조차 샘플별 최적의 weight를 선택해도 정확도 100%에 도달하지 못했다.
이는 AdaptVis가 training-free로 inference 시점의 attention/decoding을 조정할 뿐, grounding 자체(무엇을 봐야 하는지)를 바꾸지 못하기 때문이다.
즉, 애초에 잘못된 영역에 주목한 샘플은 weight를 조절해도 해결되지 않으며,
결과적으로 남은 격차는 지표의 문제가 아니라 **AdaptVis 전략 자체의 구조적 상한(ceiling)임**을 시사한다.

기타 실험 | 프롬프트 기반 접근

RQ. 희소한 언어에서 영어를 거쳐 한국어로 번역되면 쉬운 task가 되듯,
공간 추론도 **중간 단계를 넣으면** 모델이 더 쉽게 풀 수 있지 않을까?

Hypothesis

두 객체를 동시에 인지하고 상대관계까지 판단하는 **복합 과제는 VLM에겐 어려운 일이다.**
따라서 **절대 위치를 파악한 후 상대 위치 파악**으로 분해하면 더 쉬운 하위 과제가 되어 성능이 개선될 것이다.

Query1: "Where is the apple located in the image? Answer with left, right, top or bottom."

Query2: "Where is the armchair located in the image? Answer with left, right, top or bottom."

Results

절대 위치 추정 자체를 대부분 실패했고,
응답이 Bottom으로 과도하게 쏠리면서 이후
단계인 상대관계 추론이 무의미해졌다.

응답	Left	Right	Top	Bottom
비율 (%)	8.2	7.5	12.1	**72.2**

즉, 이 설정에서 절대 위치 추정은 '쉬운 하위
과제'가 아니었던 것이다.

RQ. 모델이 공간 관계를 제대로 이해했다면, **질문 방향을 바꿔도 논리적으로 일관된 답**이 나와야 하지 않을까?

Method

동일한 객체 쌍에 대해 정방향/역방향 질문을 했을 때
1) 답이 일관된 관계(Left↔Right, On↔Under)를 만족하면 신뢰하여 그대로 사용한다.
2) 그렇지 않으면 해당 샘플은 불확실하다고 보고 baseline 추론으로 fallback한다.

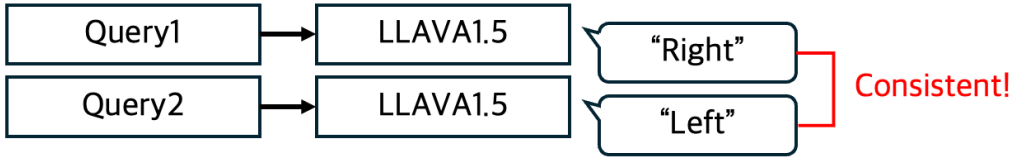

Results

유형	샘플 수	비율 (%)
양방향 동일 응답 (예: 둘 다 Left)	247	60.8
불일치 (예: Left와 On)	138	34.0
논리적 일관성 (예: Left ↔ Right)	21	5.2

모델이 관계를 계산하기보다
편향된 답을 반복하는 경향을 보인다.

두 방법 모두 모델이 안정적으로 grounding한다는 전제가 있어야 하는데, 실제로는 거의 성립하지 않아 다음 단계의 프롬프트가 신뢰할 중간 신호를 만들지 못했다.
즉, 문제는 질문 방식이 아니라 모델이 시각적 근거 자체를 잘 잡아내지 못하는 것이므로, 프롬프트만으로는 개선 여지가 작고 오히려 오류를 누적시키기 쉽다.

Research Project 2

2025.03 ~ 2025.06

CLIP Feature Disentangling for fine-grained task

- CLIP이 Fine-grained task에서 유사 클래스를 혼동하는 원인(Feature Entanglement) 분석
  - 논문 기반 전체 파이프라인 From Scratch 구현 및 새로운 평가 지표 제안

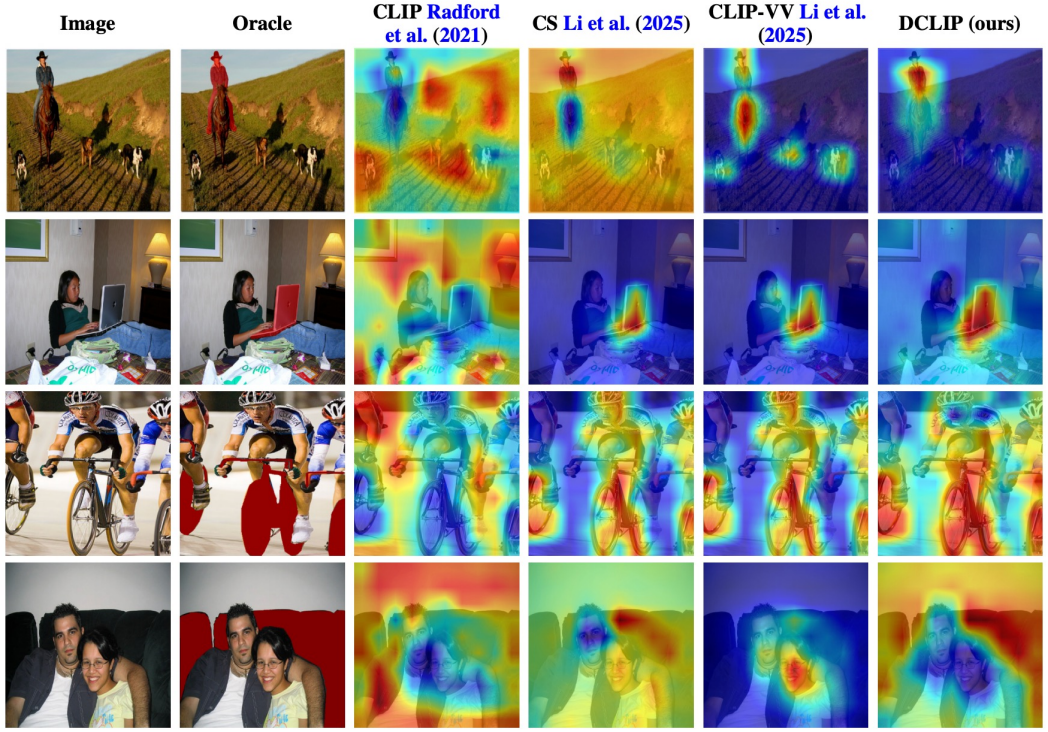

Baseline 논문

Efficiently Disentangling CLIP for Multi-Object Perception

🔗 Link: https://arxiv.org/pdf/2502.02977

[요약]

- CLIP이 Zero-shot Semantic Segmentation(ZS3)과 같은 fine-grained task를 어려워하는 원인을 feature entanglement로 규명
- MFI Loss로 클래스 간 feature를 orthogonalize하여 inter-class similarity 30% 감소

본 프로젝트는 DCLIP 프레임워크를 기반으로

아래 항목들을 연구한다:

1) from-scratch baseline code implementation

2) 새로운 평가 metric 제안

3) 새로운 loss 제안

Research Project 2

From-scratch Baseline Code Implementation

Goal

비공개 코드 논문을 기반으로 paper-only baseline을 구현하고,
학습, 평가, 시각화까지 파이프라인 완성

Setup

- Backbone: OpenAI CLIP (ResNet101), frozen
- Trainable: lightweight text/image projector
- Loss / Logits: ASL + MFI
- Visualization: CLIP Surgery 기반 CAM을 baseline 구조에 맞게 수정

Results

VOC2007 mAP 94.16 달성 (paper: 95.4)
CAM 시각화도 논문 의도(로컬 활성화 확인)에 맞게 일관된 출력 확보

Artifact

Code: https://github.com/haewon22/DCLIP.git

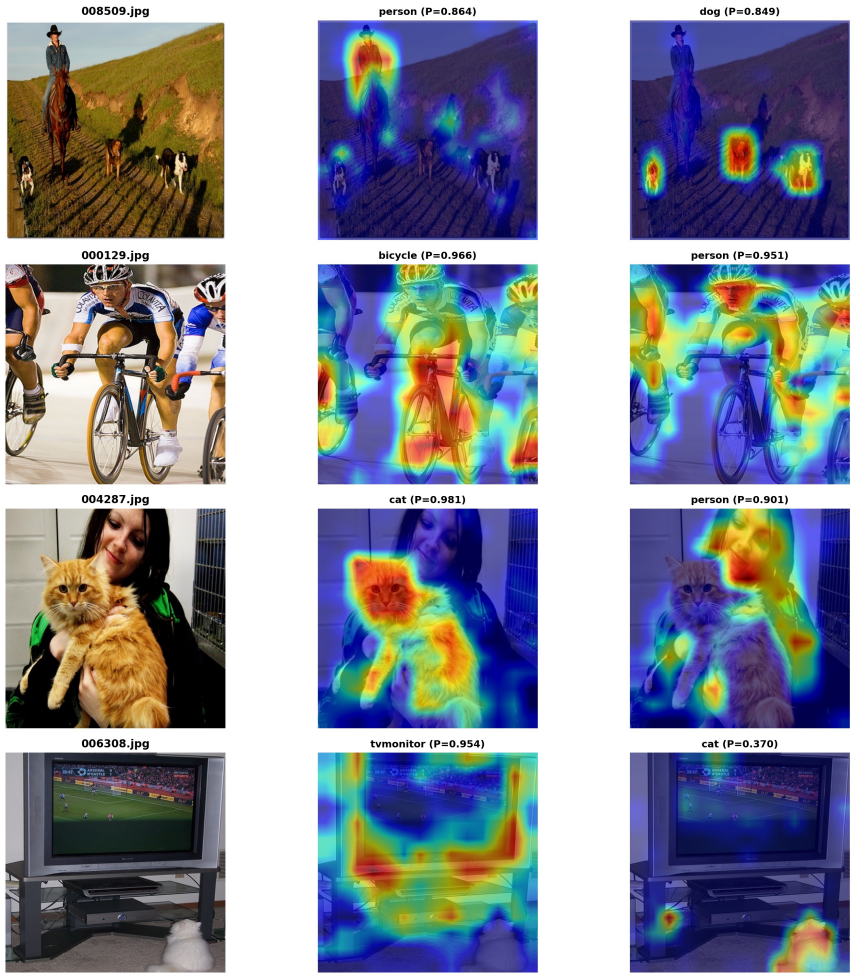

구현한 DCLIP visualization 결과

새로운 Metric 제안 | UnmixRate

RQ. mAP로는 유사 클래스를 얼마나 혼동하는 지 직접 측정하기 어렵다.
타겟 자체를 잘 잡는지와, 유사 클래스를 헷갈려하지 않는지를 동시에 평가할 수 없을까?

계산 과정

Negative 클래스 정의

1) VOC 클래스 간 inter class similarity 계산
2) 각 타겟 클래스에 대해 가장 유사한 Top-N 클래스를 "헷갈리기 쉬운 클래스"로 정의
   예: cat → {dog, bird, cow, horse, ...}

Zero-shot Semantic Segmentation(ZS3)

1) 타겟(positive) 클래스에 대해 ZS3 수행
2) Negative 클래스에 대해 ZS3 수행
3) 각 결과에 대해 thresholding → *figure1*

UnmixRate 계산

1) 타겟(positive) 클래스의 GT 마스크와 positive 클래스의 ZS3 결과에 대해 IoU 계산
2) 타겟(positive) 클래스의 GT 마스크와 각 negative 클래스의 ZS3 결과에 대해 IoU 계산
3) (1-Negative 클래스의 IoU 평균) 계산
4) positive 클래스의 IoU와 (1-Negative 클래스의 IoU 평균 계산) 간 조화평균 계산

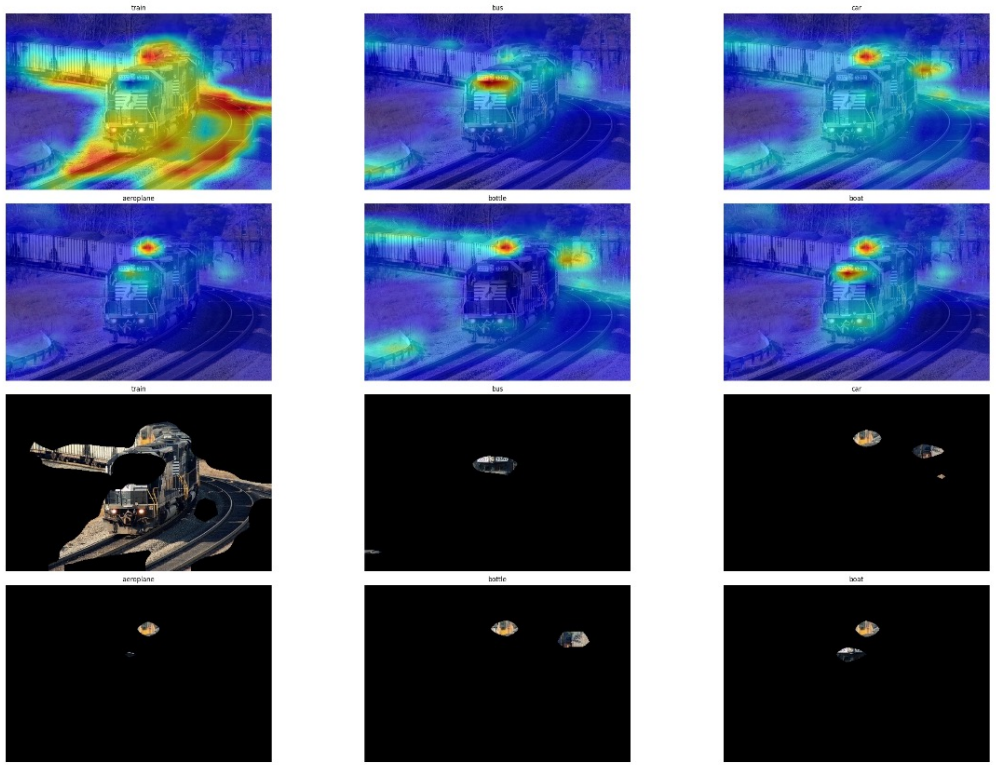

figure 1. thresholding을 통한 마스크 생성

Research Project 2

새로운 Metric 제안 | Results

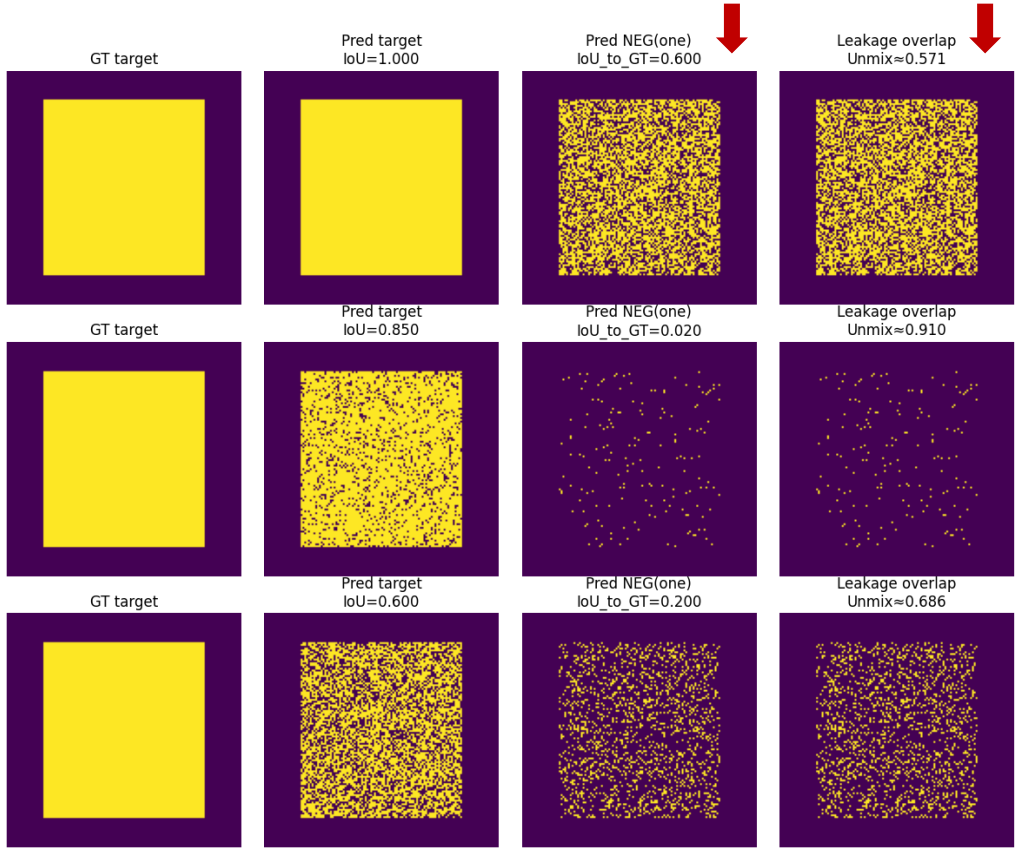

UnmixRate 지표 검증

실험조건	TargetIoU	Leakage	UnmixRate
높은 IoU + 높은 Leakage	1.000	0.600	0.571
높은 IoU + 낮은 Leakage	0.850	0.020	0.910
중간 IoU + 중간 Leakage	0.600	0.200	0.686

합성 마스크로 negative leakage를 조절해 UnmixRate이 타겟 IoU뿐 아니라 유사 클래스 침범까지 함께 반영하는지 검증했다.
동일하거나 높은 타겟 IoU에서도 leakage가 커지면 UnmixRate가 유의미하게 감소했고, 반대로 leakage가 낮으면 UnmixRate가 높게 유지됐다.
즉, UnmixRate는 타겟을 잘 잡는지에 더해 다른 클래스를 혼동하지 않았는지까지 평가하는 지표임을 의미한다.

Research Project 2

새로운 loss 제안 (HNS)

RQ. 기존 MFI의 s^2은 similarity를 0(orthogonal)으로 유도하는데, 이를 s^3으로 바꿔 negative 방향까지(180도로) 더 밀어 주면 분리력이 더 좋아지지 않을까?
특히 이미 negative similarity인 잘 분리된 쌍을 s^2로 penalty 처리 하는 건 오히려 손해이지 않았을까?

(Base) MFI loss : $L_{MFI} = \sum_{i=1}(s_{ii} - 1)^2 + \lambda \sum_{i=1} \sum_{j=1, i \neq j} s_{ij}^2$

(Ours) HNS loss : $L_{HNS} = \sum_{i=1}(s_{ii} - 1)^2 + \lambda \sum_{i=1}^{N} \frac{\beta}{\mu_i + \varepsilon} \sum_{j \neq i} s_{ij}^3$

Results

Metric	DCLIP	DCLIP+HNS	Δ
mAP	94.16	94.07	- 0.09
TargetIoU	0.3709	0.3721	+ 0.0012
Leakage	0.0194	0.0295	+ 0.0101
UnmixRate(ours)	0.5068	0.5079	+ 0.0011

1) HNS의 s^3 은 유사도가 높은 클래스 쌍을 더 강하게 밀어내, 타겟 활성화가 강해지며 TargetIoU가 소폭 상승하였다.

2) 그러나 s^3로 인해 동시에 유사 클래스가 함께 활성화되는 Leakage도 증가한다.

3) 결과적으로 HNS는 두 지표를 동시에 개선하지 못했으며, 전역적인 분리 보다는 confusable 쌍을 직접 타겟팅하는 방식을 다음 방향으로 고려할 수 있다.

Research Project 2

Main Results

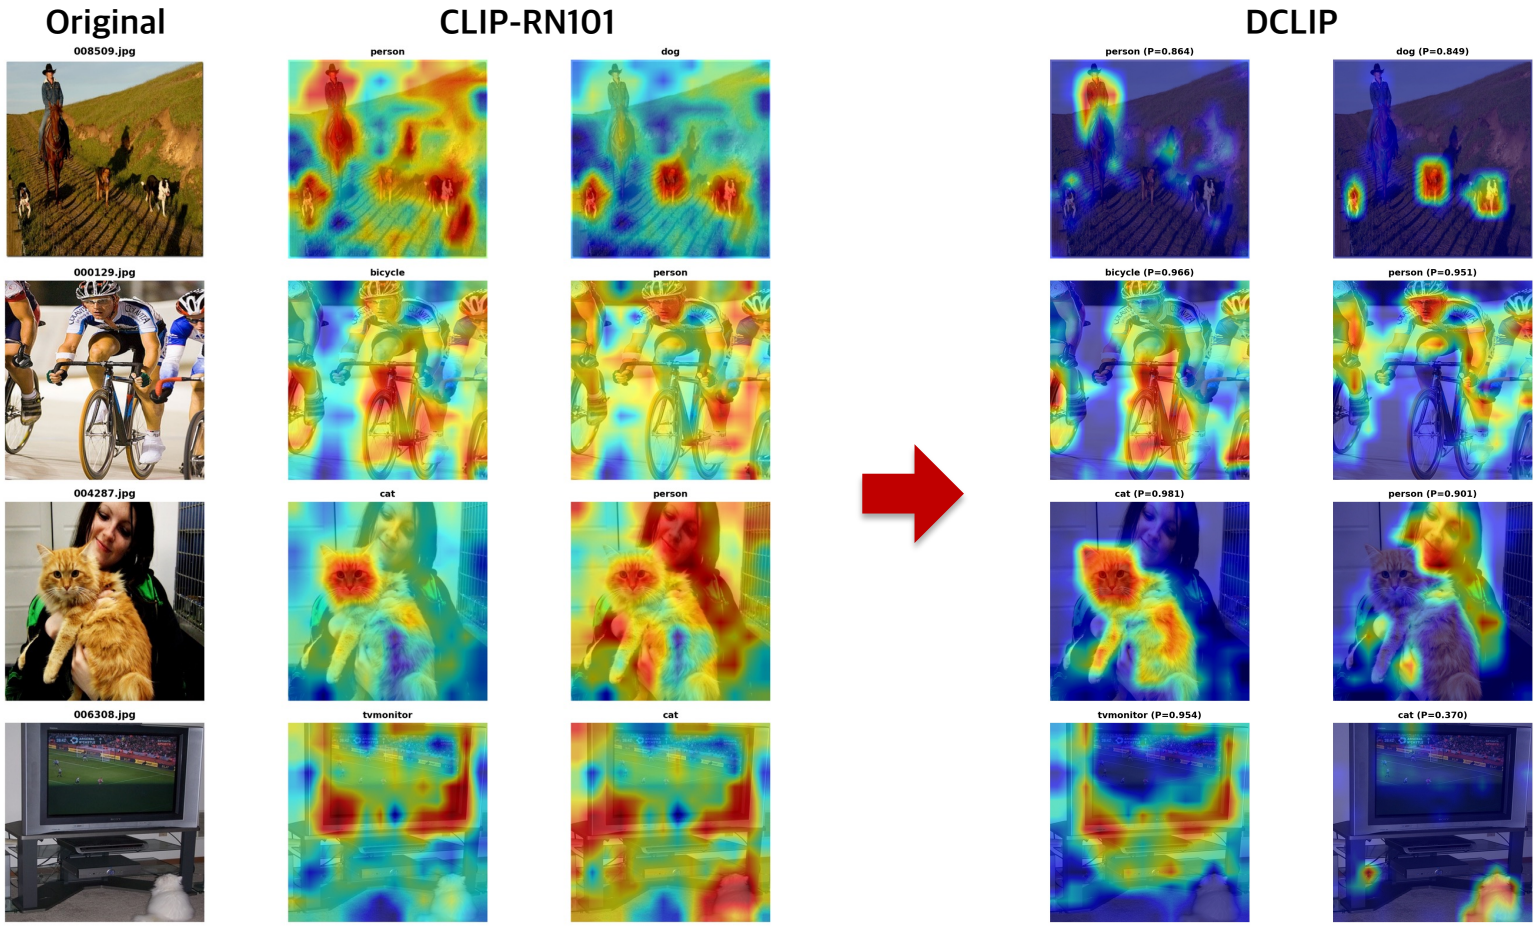

Method	mAP↑	UnmixRate(ours)↑	TargetIoU↑	Leakage↓
CLIP-RN50	76.54	0.2971	0.2185	0.0788
CLIP-RN101	77.34	0.3127	0.2563	0.1818
CLIPSurgery-CS-RN101	84.89	0.4141	0.3197	0.0833
DCLIP-RN101	**94.16**	0.5068	0.3709	**0.0194**
DCLIP-RN101+HNS(ours)	94.07	**0.5079**	**0.3721**	0.0295

1) DCLIP 재현: paper 95.4 대비 94.16 mAP 달성

2) Vanilla CLIP-RN101 대비 mAP +17%p, Leakage 75% 감소

이는 시각화 결과에서도 명확히 확인 가능